

4.8 performance & scalability plans

برنامه‌های عملکرد و مقیاس‌پذیری - ProDecks

نسخه: 1.0

تاریخ: 1403/11/16

برنامه‌ریزی شده - MVP: وضعیت

فصل ۱: مرور کلی

هدف این سند ۱.۱.

در مواجهه با رشد کاربران ProDecks تعیین استراتژی‌ها و برنامه‌های لازم برای تضمین عملکرد بهینه و مقیاس‌پذیری سیستم و داده‌ها.

چالش‌های پیش‌رو ۱.۲.

- رشد تصاعدی تعداد کاربران و داده‌ها
- افزایش انتظارات کاربران از زمان پاسخ‌گویی
- (High Availability) نیاز به دسترسی‌پذیری بالا
- حفظ هزینه‌های زیرساخت در سطح منطقی

اهداف کلیدی ۱.۳.

- برای ۹۵٪ درخواست‌ها ms زیر ۲۰۰ API زمان پاسخ
- زمان لود صفحات: زیر ۳ ثانیه
- (Uptime) دسترسی‌پذیری: ۹۹.۹٪
- پشتیبانی از ۱۰,۰۰۰ کاربر همزمان
- مقیاس‌پذیری خطی هزینه با رشد کاربران

فصل ۲: معیارهای عملکرد (Performance Metrics)

معیارهای کاربردی ۲.۱. (Application Metrics)

- API Response Time:
 - P50: < ۱۰۰ms
 - P95: < ۲۰۰ms
 - P99: < ۵۰۰ms
- Page Load Time:
 - First Contentful Paint: < ۱.۵s

- Largest Contentful Paint: < ۲.۵s

- Time to Interactive: < ۳.۵s

• Transaction Rate:

- کارت ایجاد/آپدیت: ۵۰ تراکنش/ثانیه

- عملیات: ۱۰۰ تراکنش/ثانیه Drag & Drop

۲.۲. معیارهای زیرساختی (Infrastructure Metrics)

• CPU Utilization: حداکثر ۷۰٪

• Memory Utilization: حداکثر ۸۰٪

• Disk I/O: ۱۰۰ms latency زیر

• Network Throughput: مطابق با الگوی ترافیک

۲.۳. معیارهای پایگاه داده (Database Metrics)

• Query Execution Time:

- ساده: > ۱۰ms

- پیچیده: > ۱۰۰ms

• Connection Pool Utilization: حداکثر ۸۰٪

• Replication Lag: < ۵ ثانیه

۲.۴. معیارهای کسب و کار (Business Metrics)

• User Satisfaction Score: > ۴.۵/۵

• Task Completion Rate: > ۹۵٪

• System Availability: ۹۹.۹٪

فصل ۳: استراتژی‌های بهینه‌سازی عملکرد

۳.۱. بهینه‌سازی فرانت‌اند

۱. Minification و Bundling:

• JavaScript و CSS ترکیب فایل‌های

• فشرده‌سازی تصاویر

• برای فایل‌های استاتیک CDN استفاده از

۲. Lazy Loading:

• بارگذاری تصاویر هنگام نیاز

• JavaScript تقسیم کد

• به تعویق انداختن بارگذاری ماژول‌های غیرضروری

۳. Caching مرورگر:

• Cache-Control headers تنظیم مناسب

• ETags استفاده از

۴.۲. مقیاس‌پذیری افقی (Horizontal Scaling)

۱. Web Tier:

- Load Balancer (NGINX/HAProxy)
- Auto-scaling گروه سرورهای وب
- Stateless ease of scaling برای طراحی

۲. Database Tier:

- Primary-Secondary Replication
- Read Replicas برای بار خواندنی
- Sharding در صورت نیاز

۳. Cache Tier:

- Redis Cluster
- Memcached با چندین نود

۴.۳. الگوهای معماری مقیاس‌پذیر

۱. Microservices (آینده):

- تفکیک سرویس‌های اصلی
- API Gateway
- Service Discovery

۲. Event-Driven Architecture:

- Message Queue (RabbitMQ/Kafka)
- Event Sourcing برای موجودیت‌ها
- CQRS read/write برای جداسازی

۴.۴. Database Scaling Plan

- Single Master + ۲ Read Replicas: تا ۱۰,۰۰۰ کاربر
- Master-Master + ۴ Read Replicas: تا ۵۰,۰۰۰ کاربر
- Sharding: بیش از ۵۰,۰۰۰ کاربر

فصل ۵: معماری مقیاس‌پذیر

۵.۱. معماری فعلی (MVP)

[CDN] → [Load Balancer] → [Web Servers] → [Database Master]
↓
[Database Replica]

معماری فاز ۲ (۱۰,۰۰۰ کاربر)

[CDN] → [Load Balancer] → [Web Servers] → [API Gateway] → [Microservices]
↓
[Message Queue] → [Background Workers]
↓

۷.۱. انواع تست‌ها

۱. Load Testing:

- شبیه‌سازی کاربران واقعی
- افزایش تدریجی بار
- bottlenecks شناسایی

۲. Stress Testing:

- بار بیش از حد ظرفیت
- شناسایی نقاط شکست
- تعیین حد نهایی سیستم

۳. Endurance Testing:

- تست طولانی مدت (۲۴-۷۲ ساعت)
- memory leaks شناسایی
- stability بررسی

۴. Spike Testing:

- افزایش ناگهانی بار
- شبیه‌سازی رویدادهای خاص
- resilience تست

۷.۲. ابزارهای تست

- Load Testing: Apache JMeter, k6
- Monitoring: Prometheus, Grafana
 - APM: New Relic, Datadog
- Database: pt-query-digest, Percona Toolkit

۷.۳. سناریوهای تست

سناریو ۱: ایجاد کارت

- کاربران همزمان: ۱۰۰ → ۵۰۰ → ۱,۰۰۰
- فرکانس: ۱۰ کارت/دقیقه به ازای هر کاربر
- throughput, error rate, معیارها: زمان پاسخ

عملیات Drag & Drop: سناریو ۲

- کاربران همزمان: ۵۰ → ۲۰۰ → ۵۰۰
- عملیات: جابجایی ۵ کارت/دقیقه به ازای هر کاربر
- real-time performance, consistency: معیارها

سناریو ۳: گزارش‌گیری

- کاربران همزمان: ۱۰ → ۵۰ → ۱۰۰
- زیاد joins گزارش‌ها: پیچیده با
- معیارها: زمان اجرای کوئری، مصرف منابع

۸.۱. معیارهای مانیتورینگ

- Application Level:
 - Response times
 - Error rates
 - Throughput
- Business transactions
- Infrastructure Level:
 - CPU/Memory/Disk usage
 - Network I/O
 - Service availability
- Database Level:
 - Query performance
 - Connection counts
 - Replication lag
 - Lock contention

۸.۲. تنظیمات هشدار

- Critical (PagerDuty/SMS):
 - Uptime < ۹۹%
 - Error rate > ۵%
 - Database down
- Warning (Email/Slack):
 - Response time P95 > ۵۰۰ms
 - CPU usage > ۸۰٪ به مدت ۵ دقیقه
 - Disk usage > ۸۵%
- Informational (Dashboard):
 - Performance degradation
 - Unusual patterns
 - Capacity thresholds

۸.۳. dashboards

- Real-time Dashboard: وضعیت لحظه‌ای
- Business Dashboard: معیارهای کسب‌وکار
- Performance Dashboard: روند عملکرد
- Capacity Dashboard: trends مصرف منابع و

- Scale Out:
 - CPU utilization > ۷۰٪ به مدت ۵ دقیقه
 - Memory utilization > ۸۰٪ به مدت ۵ دقیقه
 - Response time P95 > ۴۰۰ms به مدت ۱۰ دقیقه
- Scale In:
 - CPU utilization < ۳۰٪ به مدت ۱۵ دقیقه
 - Memory utilization < ۴۰٪ به مدت ۱۵ دقیقه

Scaling زمان بندی ۹.۲.

- Scheduled Scaling:
 - ظرفیت +۵۰٪ (۹AM-۵PM): ساعت اوج مصرف
 - ظرفیت -۵۰٪ (۱۲AM-۶AM): ساعت شب
 - آخر هفته: -۳۰٪ ظرفیت
- Event-based Scaling:
 - رویدادهای بازاریابی: +۱۰۰٪ ظرفیت
 - جدید: +۵۰٪ ظرفیت feature انتشار

Scaling استراتژی ۹.۳.

- Conservative: scaling افزایش ۱ نود در هر
- Aggressive: scaling events افزایش ۲-۳ نود در
- Predictive: برای پیش بینی بار machine learning استفاده از

فصل ۱۰: بهینه سازی هزینه

استراتژی های کاهش هزینه ۱۰.۱.

- ۱. Spot Instances استفاده از:
 - های قابل تحمل خطا workload برای
 - صرفه جویی تا ۷۰٪
 - stability برای on-demand instances همراه با

۲. Right-sizing:

- مانیتورینگ مداوم مصرف منابع
- instances تنظیم اندازه
- حذف منابع بلااستفاده

۳. Reserved Instances:

- های پایدار workload برای
- صرفه جویی تا ۴۰٪
- برنامه ریزی بلندمدت

- origin برای کاهش بار CDN استفاده از
- caching aggressive برای کاهش بار دیتابیس
- ارزان برای داده‌های قدیمی object storage استفاده از
- داده‌ها در انتقال و ذخیره‌سازی compression

۱۰.۳. مدیریت چرخه حیات داده

- ارزان‌تر storage انتقال داده‌های قدیمی به
- archiving پروژهای کامل شده
- حذف خودکار داده‌های موقت
- retention policies بر اساس ارزش داده

۱۱ Disaster Recovery و Business Continuity: فصل ۱۱

۱۱.۱. Backup استراتژی

- هر ساعت incremental + روزانه Backup: داده‌ها
- versioning خودکار با Backup: پیکربندی
- تست بازیابی: ماهانه

۱۱.۲. Recovery استراتژی

- Recovery Time Objective (RTO): ساعت ۴
- Recovery Point Objective (RPO): ساعت ۱
- Regional Failover: اصلی در صورت قطعی

۱۱.۳. High Availability طراحی

- Multi-AZ deployment برای سرویس‌های حیاتی
- Load balancing across zones
- Automated failover mechanisms

۱۲: نقشه راه مقیاس‌پذیری فصل ۱۲

۱۲.۱. فاز ۱ (ماه‌های ۱-۳): پایه‌های مقیاس‌پذیری

- لایه caching پیاده‌سازی
- بهینه‌سازی کوئری‌های اصلی
- پایه monitoring تنظیم
- اولیه load تست

۱۲.۲. فاز ۲ (ماه‌های ۴-۶): مقیاس‌پذیری اولیه

- ریسک: Database becoming bottleneck
- Mitigation: Read replicas, caching, query optimization

- ریسک: Single point of failure
- Mitigation: Multi-AZ, failover automation

- ریسک: Cost overrun
- Mitigation: Cost monitoring, right-sizing, reserved instances

ریسک‌های عملیاتی ۱۴.۲.

- ریسک: Lack of monitoring
- Mitigation: Comprehensive monitoring, alerting

- ریسک: Insufficient testing
- Mitigation: Regular load testing, chaos engineering

- ریسک: Knowledge silos
- Mitigation: Documentation, cross-training

ریسک‌های کسب‌وکار ۱۴.۳.

- ریسک: Performance affecting user retention
- Mitigation: Performance SLAs, proactive monitoring

- ریسک: Inability to handle growth spikes
- Mitigation: Auto-scaling, capacity buffer

- ریسک: Competitive disadvantage
- Mitigation: Continuous performance improvement

فصل ۱۵: نتیجه‌گیری

یک رویکرد جامع و مرحله‌ای برای تضمین ProDecks برنامه عملکرد و مقیاس‌پذیری تجربه کاربری بهینه در تمام مراحل رشد کسب‌وکار ارائه می‌دهد. با ترکیب بهینه‌سازی‌های فنی، استراتژی‌های مقیاس‌پذیری هوشمند و فرآیندهای عملیاتی دقیق، ما آمادگی لازم برای رشد تصاعدی را خواهیم داشت.

- تمرکز ما نه تنها روی مقیاس‌پذیری فنی، بلکه روی مقیاس‌پذیری اقتصادی نیز هست. حفظ کیفیت سرویس در حالی که هزینه‌ها به صورت خطی با رشد افزایش می‌یابند.

ضمیمه‌ها

اولیه load ضمیمه ۱: نتایج تست‌های

